

中南民族大学

研究生学位论文开题报告表

学号	2024120408
姓名	李航
培养学院	计算机学院（人工智能学院）
学科专业	计算机技术
研究方向	深度学习
指导教师	莫海芳
学习年限	2024 年 9 月至 2027 年 6 月
开题日期	2026 年 4 月 22 日
论文题目	基于句法引导与细粒度调制的视觉 定位算法研究

中南民族大学研究生院制表

关于研究生学位论文开题报告的规定

根据《中华人民共和国学位条例》、《中南民族大学学位授予工作细则》的精神，为做好研究生学位论文的开题报告，保证学位论文质量，特作如下规定：

第一条 学位论文开题报告是研究生论文写作的必经过程，所有研究生在修完学位课程，中期考核通过，进行学位论文写作之前，都必须做开题报告。

第二条 开题报告主要检查研究生掌握专业理论的程度和研究能力，考察学位论文准备工作是否深入细致，包括选题是否恰当，资料占有是否翔实、全面，对国内外的研究现状是否了解，本人的研究是否具有开拓性、创新性等。

第三条 学位论文开题报告前，研究生必须根据专业培养目标，结合导师、教研室（或研究室）所承担的国家、省部委等有关部门下达的研究项目或课题以及本人的研究特长，与导师协商，确定选题，广泛查阅文献，深入调研，收集资料，制定研究方案，在此基础上撰写开题报告。

第四条 研究生进行开题报告，内容包括：（1）论文选题的理由和意义；（2）国内外关于该论题的研究现状及趋势；（3）本人的研究计划，包括研究目标、内容、拟突破的难题或攻关的难关、自己的创新或特色、研究方法或实验方案、写作计划等；（4）主要参考文献目录。

第五条 研究生进行学位论文开题报告，需向导师提出申请。申请获准后，参加开题报告的教师，包括导师在内，一般不得少于3人。在做开题报告时，本学科专业的研究生一般必须参加，跨学科或相近专业的研究生亦可旁听。

第六条 参加研究生学位论文开题报告的教师应当对开题报告进行评议，主要评议论文选题是否恰当，研究设想是否合理、可行，研究内容与方法是否具有开拓性、创新性，研究生是否可以开始进行论文写作等。

第七条 表中各项可自行加页。

姓 名	李航	性别	男	民族	回	出生年月	2002.06
培养学院	计算机学院（人工智能学院）	专业	计算机技术		研究方向	深度学习	
论文	中文	基于句法引导与细粒度调制的视觉定位算法研究					
题目	英文	Research on Visual Grounding Algorithms Based on Syntactic Guidance and Fine-Grained Modulation					
一、立论依据：内容包括 1.选题的缘由；2.研究意义；3.国内外相关文献综述。							
1.选题缘由 视觉语言预训练模型（Vision-Language Pre-training, VLP）通过在大规模图文数据上进行联合训练，使模型具备跨模态语义理解与对齐能力，在图文检索、视觉问答和图像描述生成等任务中取得了显著成果[1-3]。视觉定位（Visual Grounding）是连接计算机视觉与自然语言处理的核心桥梁，其目标是让机器能够根据一句自然语言描述，在视觉场景中精准地定位或分割出所指代的目标。这项技术包含两个核心子任务：指称表达理解（Referring Expression Comprehension, REC），即以边界框（Bounding Box）形式定位目标；以及指称表达分割（Referring Expression Segmentation, RES），即以像素级掩码（Mask）形式精细地分割出目标轮廓[4]。视觉定位问题的核心在于建立视觉信息与语言表达之间的细粒度语义对应关系，其难点主要体现在两个方面：一是视觉场景中目标之间存在高度相似性，易引发语义歧义；二是自然语言表达具有多样性与不确定性，使得跨模态对齐过程更加复杂[5]。因此，该任务在智能机器人、自动驾驶、增强现实等应用场景中具有重要的研究价值和应用前景[6]。 2.研究意义 近年来，随着大规模预训练模型的发展，视觉定位研究逐步向统一建模与通用化的方向演进。具体而言，“统一建模”是指打破视觉与语言模块独立设计、分层处理的传统壁垒，通过完全共享的 Transformer 网络（如单塔架构）在同一特征空间内实现图文信息的深度交互；而“通用化”则是指模型摆脱了针对单一封闭数据集的定制设计，转而通过海量图文对比预训练（如 CLIP），具备了处理开放词汇（Open-Vocabulary）场景的泛化能力[7]。在此背景下，OneRef 模型提出了一种统一的单塔结构框架，通过掩码指代表达建模（Mask Referring Modeling）实现视觉与语言的深度交互，在指代表达理解与分割任务中取得了优异性能[8]。视觉语言预训练模型中已隐含丰富的跨模态对齐知识，通过合理设计任务形式，可以有效挖掘其在视觉定位中的潜力[9]。尽管现有研究取得了显著进展，但视觉定位任务仍面临诸多挑战： (1) 长难句与复杂逻辑下的注意力弥散问题，现有模型的自注意力机制主要依赖数据驱动，缺							

乏对文本内部修饰关系与指代逻辑的显式结构约束，导致模型在处理长文本时极易受冗余词汇干扰，产生注意力分散与逻辑误判；

(2) 目标边缘细节丢失问题，在指称表达分割任务中，现有单塔模型受限于浅层线性网络的解码能力，特征重构过程易产生平滑效应，难以精准刻画复杂背景下不规则目标的轮廓与边缘纹理；

(3) 跨模态特征往往削弱网络对图像二维物理坐标的感知问题，导致模型在面对密集或高度相似目标区域时，易发生空间定位的混淆与偏移。

同时，当前方法在很大程度上依赖大规模人工标注数据，标注成本高且限制了模型在实际场景中的应用[6]。此外，不同数据分布之间的差异也会影响模型的泛化性能，使其在真实场景中的表现存在不稳定性。

基于上述背景，开展“基于视觉语言预训练模型的视觉定位算法研究”具有重要的理论意义与实际价值。在理论层面，该研究有助于深化对视觉与语言跨模态语义对齐机制的理解，推动多模态统一建模方法的发展；在应用层面，该研究可为智能机器人、人机交互系统及自动驾驶等领域提供关键技术支撑，提升系统在复杂环境中的感知与理解能力。

3. 国内外相关文献综述

目前，对于视觉定位任务，按照模型架构与特征交互方式的演进，主要可划分为基于两阶段候选区域的方法、基于端到端架构的方法，以及基于多模态大模型与统一架构的方法三大类。

(1) 基于两阶段候选区域的视觉定位方法

早期的视觉定位方法主要依赖于“先检测，后匹配”的两阶段范式。此类方法通常先利用现成的目标检测器从图像中提取一系列候选区域 (Region Proposals)，随后提取文本特征，并通过计算两者的相似度来筛选最佳目标。Kazemzadeh 等人[9]最早构建了 ReferItGame 数据集，确立了基于候选框匹配的视觉定位基础框架。为了增强目标与环境的关联判别，Nagaraja 等人[5]提出了一种基于上下文建模的方法，通过提取目标周边区域的视觉特征来辅助消除语义歧义。Yu 等人[10]提出了一种模块化注意力网络 (MAttNet)，该方法创新性地将复杂的自然语言表达分解为“主体、位置、关系”三个模块，分别计算与视觉候选框的匹配得分，显著提升了细粒度对齐能力。传统的两阶段方法虽然能够直接利用成熟的目标检测技术，但也存在明显的局限性。首先，整个系统的性能上限严重受限于第一阶段候选框的生成质量，一旦检测器漏检，后续模型将无法挽回；其次，特征提取过程计算复杂度高，难以实现实时的跨模态推理。

(2) 基于端到端架构的视觉定位方法

为了克服两阶段方法计算冗余及误差累积的缺陷，研究者开始探索去除目标检测器、直接回归坐标的端到端 (End-to-End) 视觉定位架构。Deng 等人[11]提出了一种基于 Transformer 的端到端框架 TransVG。该模型完全摒弃了锚框设计和非极大值抑制 (NMS)，直接将图像的网格特征与文本特征输入 Transformer 编码器，实现了坐标的直接预测，开创了无候选框检测的新阶段。杨晓山等人[12]进一步精简了模型，提出了 SimVG 框架，该研究证明了无需复杂的特定任务模块，仅通过简单的跨

模态特征融合与回归头, 亦能取得极具竞争力的定位性能。针对拥挤场景下单一目标监督不足的问题, 戴明等人[13]提出了一种基于多粒度判别的端到端方法 PropVG, 通过引入对比学习模块, 促使模型不仅关注目标特征, 还能有效抑制背景干扰物。端到端方法极大提升了模型的推理速度与架构简洁度。然而, 在缺乏预设候选框的引导下, 模型对全图网格特征直接进行全局推理, 往往容易在密集相似目标中丢失空间位置的精确感知。

(3) 基于多模态大模型与统一架构的视觉定位方法

近年来, 视觉语言预训练 (VLP) 范式迅速崛起。研究者致力于构建统一的多模态基座, 通过在大规模数据上进行预训练, 实现 REC 与 RES 任务的深度融合与架构统一。在早期的 VLP 探索中, Li 等人[1]与 Lu 等人[2]分别提出了 VisualBERT 与 ViLBERT, 利用多层 Transformer 构建了图像区域与文本序列的共享表示空间。随后, Radford 等人[7]提出了 CLIP 模型, 利用数亿级别的图文对进行对比学习, 构建了极其强大的全局语义对齐空间。赵树阳等人[14]基于此提出了 CLIP-VG, 利用自适应课程学习成功将 CLIP 的知识迁移至密集的视觉定位任务中。随着生成式建模与掩码学习的发展, 多模态架构迎来了向单塔 (One-tower) 收敛的趋势。Wang 等人[15]提出的 OFA 模型将多模态定位任务转化为了通用的序列生成任务; 而随后提出的 BEiT-3 模型[16]则将图像块建模为离散标识, 通过纯粹的掩码数据建模统一了多种视觉任务。Flamingo 模型[17]进一步展示了跨模态少样本学习的统一能力。在特征微调与双塔结构的图谱增强层面, Yu 等人[18]提出了 ERNIE-ViL, 引入了场景图知识。庄宇等人[19]构建了层次化多模态调制网络 (HiVG), 实现了更深层次的语义融合。肖林辉等人[8]针对现有模型跨模态交互繁琐的痛点, 提出了极简的单塔结构模型 OneRef。该研究将图文特征映射到完全共享的空间, 实现了定位与分割任务的完全统一。刘昕璞等人[20]则提出了 DeRIS 框架, 通过解耦感知与认知过程有效提升了复杂背景下的分割鲁棒性。

总体来看, 视觉定位方法已从繁冗的两阶段设计全面迈向极简的单塔统一架构。现有单塔模型在追求极致简化的同时, 依然面临着严峻的挑战: 首先, 在长文本和复杂语义关系场景下, 模型对语言结构的建模能力仍然有限, 易出现注意力分散问题; 其次, 视觉与语言之间的细粒度对齐仍不充分, 影响定位精度; 最后, 在指代表达分割任务中, 模型对目标边界与细节结构的刻画能力仍存在不足。因此, 在单塔架构的基础上, 研究融合结构化句法先验、扩散去噪生成机制以及空间辅助监督的视觉定位方法, 是解决当前复杂场景泛化瓶颈的关键所在。

二、研究方案：主要包括 1.研究目标；2.研究内容；3. 拟创新之处；4.拟采用的研究方法、实验方案或可行性分析；5.研究计划与进度安排；6.主要参考文献。

1.研究目标

针对现有基于单塔架构的视觉定位算法在复杂长难句推理、掩码特征重构以及跨模态空间对齐等场景下出现的技术难题，本项目将进一步研究，期望达成如下目标：

(1) 研究并构建一种融合句法依赖引导的跨模态注意力调控方法。通过在 One-tower 架构中引入文本句法树结构信息，探讨并解决复杂开放环境下由多目标干扰、多关系交织以及长难句修饰引起的注意力弥散问题。

(2) 利用扩散去噪机制优化视觉定位与分割的一体化网络，实现对目标掩码的清晰重构与边缘结构的精准细化，显著提升模型在复杂背景下的分割交并比 (mIoU) 与定位精度。

(3) 探究并设计基于位置引导文本提示 (PTP) 的辅助监督策略，在不增加推理成本的前提下，强化模型在统一特征空间中对“文本描述-视觉网格”映射关系的理解，提升模型的空间泛化与对齐能力。

2.研究内容

(1) 现有的单塔视觉定位模型在处理长难句（如 RefCOCOg 数据集）时，常因冗余词汇的干扰导致跨模态注意力流向错误的视觉区域，出现逻辑推理失败或定位偏差的问题。该问题主要是由于模型在特征融合时缺乏对语言内部逻辑链条的显式认知。为了解决此类由复杂语义关系引起的注意力弥散问题，本文在 OneRef 的基础上，研究基于句法依赖引导的注意力调控方法。利用 NLP 工具提取文本的句法依存树，将词语间的修饰与指代关系转化为注意力掩码 (Attention Mask) 矩阵。通过对注意力流动施加结构化约束（如引入依存距离偏差），引导模型聚焦于核心语义，增强其对多目标、多关系场景的复杂推理能力。

(2) 通过对 MRefM（掩码指代建模）的重构过程进行探讨，不难发现简单的线性投影或 MLP 层难以高质量地还原被掩盖的视觉特征。这就导致了现有模型在指称分割 (RES) 任务中生成的掩码特征较为模糊，容易丢失目标物体的边缘细节与纹理结构。为了进一步增强网络对视觉特征的重构能力，解决线性层与复杂掩码特征分布不兼容的问题，本文将扩散模型 (Diffusion Model) 与掩码重构机制相结合，研究基于扩散去噪引导的掩码重构模块。在训练阶段，对掩码区域添加高斯噪声，利用扩散头强大的分布建模能力引导模型进行去噪还原；并在推理阶段作为特征细化器，强化对目标边缘和空间结构的捕捉，提高掩码预测的边界精度。

(3) 鉴于单塔模型主要依赖端到端的对比或回归损失进行学习，在处理细粒度的跨模态映射时，难以有效建立“文本指令”与“视觉坐标”之间的显式空间关联，常导致其在密集场景下出现目标定位的混淆或偏移。研究引入基于位置引导的文本提示 (Position-guided Text Prompt, PTP) 并构建多任务联合学习框架。在保留原有推理结构不变的前提下，于训练阶段增加辅助分类头 (Auxiliary Head)，

要求模型预测指代物体所属的网格索引。通过将连续的坐标回归转化为离散的区域预测任务，为模型提供显式的空间对齐信号，降低跨场景应用时的定位误检率。

3.拟创新之处

(1) 融入句法依赖的注意力机制优化

在传统单塔视觉定位模型的自注意力计算中，主要依赖数据驱动来学习词汇与图像块 (Patch) 的对齐，而对文本内部的修饰与指代逻辑缺乏显式约束，导致模型在处理长难句时容易出现注意力分散或逻辑误判。因此在 One-tower 编码器原有的注意力机制基础上设计一种基于依存距离的软性注意力偏置 (Soft Bias)，根据词汇在句法树上的关联距离，计算出一个负惩罚项并直接加到自注意力分数上，距离越远，惩罚越大。对无直接关联的词汇仅赋予一个合理的较小负值（而非绝对负无穷）。

将文本中提取的核心依存关系作为先验权重，动态调整跨模态注意力的分配，使模型在推理过程中能够沿着“主体-方位-参照物”的逻辑链条进行聚焦，有效抑制冗余词干扰；提高模型对前置句法解析错误的容错率，并在训练中保护梯度流不被破坏，确保网络更加稳健地收敛。

(2) 引入扩散去噪的掩码重构策略

现有 OneRef 模型的 MRefM 模块在重构视觉掩码特征时，受限于浅层线性网络的拟合能力，导致在复杂背景或不规则目标场景下分割轮廓模糊、边缘细节丢失。研究在 MRefM 模块中引入轻量级扩散去噪生成头 (Diffusion Head)，通过前向加噪与反向去噪的联合机制，增强模型对关键纹理、边缘形态及局部结构特征的还原响应，并克服简单重构带来的特征平滑效应。使模型在不同尺度、遮挡及复杂光影下能保持高质量的掩码生成能力，提高指称分割任务下的目标轮廓清晰度与边界平均精度 (Boundary AP)。

(3) 基于位置提示 (PTP) 的辅助监督架构

端到端单塔模型在跨模态定位任务中易过度拟合浅层图文相关性，而对图像网格的空间位置缺乏敏感度，导致在密集或相似目标区域中出现定位混淆和偏移，降低了模型的空间泛化能力。研究在模型训练阶段引入基于 PTP (Position-guided Text Prompt) 的辅助监督模块，并结合视觉定位任务的特性，将连续的边界框回归转化为目标所在网格 (Grid ID) 的分类预测，使其能够更有效地对“文本”与“视觉空间坐标”进行特征对齐。推理阶段移除该辅助模块，在不增加计算开销的前提下，显著增强模型对空间位置的感知能力。

4.研究方法

(1) 数据集介绍

本研究选用目前该领域最权威的三个主流基准数据集进行模型训练与评估。这三个数据集均基于 MS COCO (Microsoft Common Objects in Context) 图像库构建，但在文本描述的侧重点与复杂度上各具特色：

RefCOCO 数据集通过双人互动游戏 (ReferItGame) 收集，包含 19,994 张图像、50,000 个目标

实例以及 142,209 条语言指代描述。文本描述通常较短（平均长度约为 3.6 个单词），主要侧重于通过简单的方位词（如“left”，“bottom”）和明显的外观属性来定位目标。该数据集分为 train、val、testA（包含多个人物目标的图像）和 testB（包含多个非人物体的图像）四个划分。

RefCOCO+ 数据集与 RefCOCO 数据规模相近，在数据收集时严格禁用了绝对方位词（如禁止使用“左边的”、“右边的”）。这一限制迫使模型不能依赖空间位置作弊，必须深入理解目标的外观、颜色、衣着及物体间的相对关系（如“穿着红衣服的人”），对模型的细粒度视觉特征提取能力提出了更高要求。

RefCOCOg 数据集在 Amazon Mechanical Turk (AMT) 平台上采用非交互式方式收集，包含 26,711 张图像、54,822 个目标和 104,560 条语言表达。描述文本为复杂的陈述句，句子平均长度达到 8.4 个单词，包含丰富的词汇和极其复杂的句法结构。该数据集是验证本项目“句法依赖引导”创新点的核心平台，用于评估模型在长难句干扰下对核心实体的逻辑推理与精准定位能力。

为了实现指称表达理解（REC，输出边界框）和指称表达分割（RES，输出掩码）的一体化训练，本研究所使用的数据集样本通常包含以下核心标签内容：

- ① 原始图像 (Image): 包含多个相似候选目标的复杂场景图。
- ② 指代文本 (Query): 如 “a man in a yellow shirt playing with a dog”。
- ③ 边界框标签 (Bounding Box): 目标物体的真实位置坐标 $[x, y, w, h]$ ，用于评估 REC 任务。
- ④ 像素级掩码标签 (Segmentation Mask): 目标物体精确的二维二进制轮廓，用于训练扩散去噪模块并评估 RES 任务。



图 1：数据集示例

(2) 数据标注与预处理

在视觉定位与指称分割一体化任务中，高质量的数据预处理直接决定了模型跨模态特征融合的准确性。由于 RefCOCO、RefCOCO+ 与 RefCOCOg 等基准数据集的原始标注结构存在差异，首先是

对多源数据标注的统一化与混合重构。针对 REC 任务, 从标注数据集中提取目标真实边框 (Bounding Box), 并将其转换为 $[x_min, y_min, x_max, y_max]$ 以及中心点模式 $[x_c, y_c, w, h]$; 针对 RES 任务, 提取目标的像素级轮廓标注, 并转换为二进制掩码矩阵 (Binary Mask), 其中目标区域像素值为 1, 背景为 0。

在视觉图像的处理与增强方面, 将所有输入的自然图像统一缩放 (Resize) 至特定的分辨率大小 (384×384), 以适配 Transformer 编码器的 Patch 划分机制。训练阶段引入随机裁剪 (Random Crop)、随机缩放 (Scale) 以及平移 (Translate) 等空间变换操作。

针对本研究引入的“句法依赖引导”创新点, 文本预处理除了基础的分词 (Tokenization) 截断、加 BOS/EOS、补 PAD、构建 padding mask 外, 还增加了结构化的句法分析。利用自然语言处理工具 (如 Spacy) 对每条文本描述进行句法依存分析。解析出词语间的修饰、指向等逻辑关系, 并构建“句法依存矩阵”。这一预处理步骤将隐式的语法关系显式化, 直接为网络计算“软性注意力偏置 (Soft Bias)”提供了精确的先验距离数据

(3) 单塔视觉语言基线模型构建与句法偏置设计

本研究以最新的 OneRef (NeurIPS 2024) 为基线模型。该模型摒弃了传统视觉定位任务中繁重的跨模态融合编码器 (Fusion Encoder), 采用极简的单塔 Transformer 架构, 在统一的特征空间中实现图像与文本的深度融合, 在检测精度与推理速度上实现了更优的平衡。在基线网络的基础上, 针对长难句引起的注意力弥散问题, 本研究对单塔编码器内部的多头自注意力机制进行了系统性改进。利用 SpaCy 提取词级句法依存树, 对有效文本位置计算真实的依存距离 d_{ij} , 而对无效的填充 (Padding) 位置视其距离为 ∞ 。据此构建非线性软性偏置项 B_{ij} :

$$B_{ij} = \begin{cases} \exp(d_{ij}/\sigma), & d_{ij} < \infty \\ \gamma, & d_{ij} = \infty \end{cases}$$

其中, σ 控制惩罚衰减速度, γ 为常数惩罚项。随后引入控制权重 λ , 将该偏置与保留了 $-\infty$ 硬约束的标准掩码 M 共同干预注意力计算:

$$\text{Attention}_{\text{syntax}}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} + \lambda B + M \right) V$$

该设计在保留网络对填充区域硬阻断的同时, 通过软惩罚有效抑制了句内冗余词汇的干扰, 保护了模型的梯度流。融入句法依赖的注意力机制流程图如图 2 所示。




图 2: 句法模块架构图

(4) 融合扩散去噪机制的掩码重构模块设计

现有单塔模型在处理 MRefM (掩码指代建模) 时, 受限于浅层线性网络的拟合能力, 常导致分割轮廓模糊。本研究在视觉掩码重构阶段引入条件扩散模型 (Conditional Diffusion Model)。在训练的前向加噪阶段, 向真实的掩码视觉特征 x_0 逐步添加高斯噪声, 直至其变为纯噪声 x_T ; 在反向去噪阶段, 引入轻量级扩散去噪生成头 (Diffusion Head), 将单塔编码器输出的跨模态融合特征 c (包含全局图像与指代文本语义) 作为条件变量, 引导网络预测并去除噪声:

$$p_{\theta}(x_{t-1}|x_t, c) = \mathcal{N}(x_{t-1}|\mu_{\theta}(x_t, t, c), \Sigma_{\theta}(x_t, t, c))$$

通过前向加噪与反向去噪的对抗协同, 强化模型对目标边缘形态及局部纹理特征的还原响应, 提高指称分割的边界精度。




图 2: 掩码重构模块方案图

(5) 位置引导文本提示模块设计

为提升跨模态定位中的空间敏感性与二维网格感知能力，本研究在模型中引入了 PTP (Position-guided Text Prompt) 辅助监督分支。具体而言，在文本输入端追加位置引导的掩码提示模板（如“The object is in block [MASK]”），并在 OneRef 的输出端预测该掩码对应的网格编号。在不改变主干预测路径的前提下，这一设计将常规连续边界框回归扩展结合了目标所在网格的离散分类监督，使模型同时学习“区域级粗定位”与“坐标级精回归”。训练时采用多任务联合优化目标，

$\mathcal{L}_{total} = \mathcal{L}_{main} + \lambda_{ptp} \mathcal{L}_{ptp}$ ，其中 $\mathcal{L}_{ptp} = \text{CE}(p_{grid}, y_{grid})$ 。该分支在训练期为主任务提供显式的空间先验，有助于加快收敛并提升定位鲁棒性；而在推理阶段，可直接剥离该 PTP 文本提示与分类输出，因此在实现性能跃升的同时实现了零额外部署开销。

(6) 可行性分析

本实验室配备了双路 NVIDIA GeForce RTX 3090 显卡 (共 48GB 显存) 与 128GB 大容量内存，结合 PyTorch 框架的分布式数据并行 (DDP) 技术，完全能够满足混合数据集的大规模预训练与微调需求。表 1: 实验环境

环境/配置项	规格/版本参数
操作系统	Ubuntu 20.04
处理器 (CPU)	Intel Xeon Silver 4214
显卡 (GPU)	NVIDIA GeForce RTX 3090 × 2
内存 (RAM)	128 GB
深度学习框架	PyTorch 2.1.0
编程语言	Python 3.8
并行计算平台	CUDA 11.8

训练策略与技术可行性：为验证改进型单塔视觉定位模型（OneRef）在复杂长难句推理及掩码精细分割上的有效性，研究构建了包含 RefCOCO 系列及 ReferItGame 的多源混合预训练数据集。预处理阶段统一了检测框与二进制掩码格式，并通过 SpaCy 解析生成句法距离矩阵，构建出标准的多任务统一数据集。数据严格按照官方标准划分为 train、val、testA 与 testB 集。考虑到基线主干网络（Backbone）已具备强大的跨模态先验知识，为防止训练初期梯度崩溃，训练方案采用两阶段微调策略：第一阶段（Warmup）冻结 Backbone 权重，使句法矩阵仅干预前向传播，并让随机初始化的扩散去噪头（Diffusion Head）和 PTP 辅助分类头初步适应当前的图文特征空间；第二阶段（Finetune）解冻全网参数进行端到端联合优化。此外，所提的 PTP 辅助监督及软性注意力偏置（Soft Bias）均通过精巧的设计，在推理阶段裁剪掉额外计算分支，不增加实际部署的计算开销。相关核心组件（如 OneRef 源码、SpaCy 等）均有成熟的开源支持，技术落地具有极高的可行性。

数据样本覆盖度可行性：实验样本均采集自真实图像与人类自然交互文本，覆盖了三种核心的跨模态推理挑战场景。其中，RefCOCO/ReferItGame 数据集文本短促、依赖简单方位（代表基础场景）；RefCOCO+ 数据集严格禁用了绝对方位词，迫使模型学习颜色、外观与相对关系（代表细粒度外观挑战场景）；目标域（重点评估集）RefCOCOg 则包含了平均长度超 8 个单词的陈述型长难句，存在多目标干扰与复杂修饰（代表高阶逻辑推理场景）。丰富的多层级场景数据分布，为验证本文提出的“句法依赖软性偏置”能否有效解决注意力弥散问题，提供了极其充分的评估条件和实验样本。

数据集	模型干预策略	验证集 (Val)	测试集 A (TestA)	测试集 B (TestB) / Test
RefCOCO+	OneRef (原作者基线)	80.43	86.46	74.26
	句法偏置模块 (Syntax)	82.4	86.93	75.99
	PTP 辅助监督模块	82.28	87.26	75.95
RefCOCOg	OneRef (原作者基线)	83.68	-	83.52
	句法偏置模块 (Syntax)	82.92	-	84.16
RefCOCO	OneRef (原作者基线)	89.2	90.95	85.34
	扩散重构辅助模块	89.2	90.94	85.84

表 2 不同语义复杂度的数据集实验验证结果

5. 研究计划与进度安排

- (1) 2025.12 - 2025.02: 收集相关资料, 准备撰写开题报告;
- (2) 2026.02 - 2026.04: 撰写开题报告, 参加开题报告答辩会;
- (3) 2026.04 - 2026.06: 认真研究相关资料, 开展实验研究, 完成论文报告初稿, 修改论文;
- (4) 2026.07 - 2026.09: 小论文投出, 精读研究目标 2 内容相关的论文, 在此基础上提炼第
创新点, 并做实实验验证结果。
- (5) 2026.10 - 2026.12: 完成论文修改后送审;
- (6) 2027.01 - 2027.03: 论文修订, 准备毕业答辩

6. 参考文献

- [1] Li L H, Yatskar M, Yin D, et al. VisualBERT: A Simple and Performant Baseline for Vision and Language[J]. arXiv preprint arXiv:1908.03557, 2019.
- [2] Lu J, Batra D, Parikh D, et al. ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks[C]. NeurIPS, 2019.
- [3] Chen Y C, Li L, Yu L, et al. UNITER: UNiversal Image-TExt Representation Learning[C]. ECCV, 2020.
- [4] Qiao Y, Deng C, Wu Q. Referring Expression Comprehension: A Survey of Methods and Datasets[J]. IEEE Transactions on Multimedia, 2020.
- [5] Nagaraja V K, Morariu V I, Davis L S. Modeling Context Between Objects for Referring Expression Understanding[C]. ECCV, 2016.
- [6] Xiao L, Yang X, Lan X, et al. Towards Visual Grounding: A Survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.
- [7] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]. ICML, 2021.
- [8] Xiao L, Yang X, Peng F, et al. OneRef: Unified One-tower Expression Grounding and Segmentation with Mask Referring Modeling[C]. NeurIPS, 2024.
- [9] Kazemzadeh S, Ordonez V, Matten M, et al. ReferItGame: Referring to Objects in Photographs of Natural Scenes[C]. EMNLP, 2014.
- [10] Yu L, Lin Z, Shen X, et al. MAttNet: Modular Attention Network for Referring Expression Comprehension[C]. CVPR, 2018.
- [11] Deng J, Yang Z, Chen T, et al. TransVG: End-to-End Visual Grounding with Transformers[C]. ICCV, 2021.
- [12] Yang X, Zhang H, Jin L, et al. SimVG: A Simple Framework for Visual Grounding[C]. CVPR

Workshops, 2022.

[13] Dai M, Cheng W, Zhuang J, et al. PropVG: End-to-End Proposal-Driven Visual Grounding with Multi-Granularity Discrimination[C]. ICCV, 2025.

[14] Xiao L, Yang X, Peng F, et al. CLIP-VG: Self-paced Curriculum Adapting of CLIP for Visual Grounding[J]. IEEE Transactions on Multimedia, 2023.

[15] Wang P, Yang A, Men R, et al. OFA: Unifying Architectures, Tasks, and Modalities Through a Simple Sequence-to-Sequence Learning Framework[C]. ICML, 2022.

[16] Wang W, Bao H, Dong L, et al. Image as a Foreign Language: BEiT Pretraining for All Vision and Vision-Language Tasks[C]. CVPR, 2023.

[17] Alayrac J B, Donahue J, Luc P, et al. Flamingo: a Visual Language Model for Few-Shot Learning[C]. NeurIPS, 2022.

[18] Yu F, Tang J, Yin W, et al. ERNIE-ViL: Knowledge Enhanced Vision-Language Representations through Scene Graphs[C]. AAAI, 2021.

[19] Zhuang Y, Wang H, et al. HiVG: Hierarchical Multimodal Fine-grained Modulation for Visual Grounding[C]. ACM MM, 2024.

[20] Dai M, Cheng W, Liu J J, et al. DeRIS: Decoupling Perception and Cognition for Referring Image Segmentation[C]. ICCV, 2025.

三、导师意见

该生的研究课题为“基于句法引导与细粒度调制的视觉定位算法研究”，该选题具有一定的应用价值。提出的研究方法和技术路线具有可行性，研究计划与安排较为合理。

同意开题并进行下一步研究计划

导师签名：

年 月 日

四、开题评审小组秘书

姓名	谢瑾	专业技术职称	讲师	签名	
----	----	--------	----	----	--

五、开题考核小组专家

姓名	专业技术职称	签名	备注
王江晴	教授		
田莎莎	副教授		
郑禄	高级实验师		
李艳红	教授		
曹钧	工程师		

六、开题回答问题记录

1.本研究提出“句法引导”解决长难句注意力弥散问题，如何将句法先验与模型的自注意力机制融合，确保有效约束注意力分配？

专家您好，我在代码层面的具体融合方式，采用的是一种“做加法的软干预”。具体来说，先用自然语言处理工具算出词语之间的句法距离，距离越远，就给它算出一个负向的惩罚分。在Transformer 计算注意力得分的时候，没有改变它原本的运算逻辑，也没有强行把某个词遮蔽掉，而是直接把刚刚算出来的“惩罚分”当作一个偏置项，做加法叠加上去。这就像是在模型自己打分的基础上，给它额外加上了一个“逻辑印象分”。这种“软结合”的好处是，既压制了无关词汇的干扰，又保证了模型训练时的梯度能顺畅回传，容错率非常高。

2.针对目标边缘细节丢失问题，拟采用的细粒度调制策略具体是什么？

针对边缘丢失的问题，我抛弃了传统那种“一步到位”的简单解码器，引入了扩散模型的思想去一点点“磨”出细节。把单塔模型提取出来的图文特征当作一个“引导条件”。在生成最终的掩码时，模型就像雕刻师傅一样，先拿一块全是噪点的毛坯，然后根据特征引导，经过多次循环，一步一步地去噪。这种“多步对抗去噪”的过程，相当于强制网络去死磕目标边缘的像素细节，最终就能把目标的轮廓非常清晰、精细地“抠”出来。

3.选题的理由，视觉定位使用单塔模型的优缺点？结合实际落地场景回答？为什么不选择大模型？

单塔最大优势架构简洁、推理高效、速度更快，大模型参数大，一般显卡带不动。我的应用场景比如最近很火的机器人进庄园和工厂，他们需要视觉定位，对分拣场景要精准抓取目标，速度要求肯定要高一些，单塔的轻量化很适合，对实时性的兼容性比大模型好。扩散模型对复杂场景效果好一些，但是可能会导致实时性体现不足，因此要扩散模块仅用于训练细化，轻量扩散头只加在掩码分支、推理步骤少，尽量减少速度损失

4.报告中谈到的三种方法是分别构建的还是结合建成一个模型？

句法偏置是嵌入在网络内部的特征提取阶段；而扩散重构和 PTP 网格分类，则是作为两个不同的任务分支挂在输出端。在模型训练的时候，我把回归的误差、分割的误差以及 PTP 的误差按比例加在一起，算出一个总误差，让网络同步进行更新。

5.三个研究目标和研究内容，它们整体的一个逻辑关系是怎样的？

第一步是解决“听懂”的问题：用句法引导，保证模型在面对长难句时，知道谁是主语，不找错对象。第二步是解决“找准”的问题：有了 PTP 的空间辅助，即使图里有三个长得一样的苹果，模型也能靠网格坐标找对位置，不发生偏移。第三步是解决“抠细”的问题：在找对对象和位置后，最后用扩散模型把目标的边缘细节完美地勾勒出来。这三步相辅相成，刚好补齐了极简架构在复杂场景下的所有短板。

开题评审小组秘书签字：

开题小组意见: (对选题依据、研究方案的可行性、可行性及创新性的评价, 存在的主要问题和改进措施)

评议结果: ☐ 优秀 ☐ 良好 ☐ 合格 ☐ 不合格

年 月 日

☐同意 ☐不同意 评议组意见。

年 月 日